





신경망 기말 발표

한동윤, 강우현, 황지인



CONCLUSIONES



강우현

초반 코드 제작
PPT 제작



한동윤

코드 완성
발표



황지인

코딩 서포트
발표

CONTENT

- 01** 목적
- 02** 프로젝트 구조
- 03** 방법론 & 설계
- 04** 학습 과정
- 05** 분석 결과
- 06** 결론 및 향후 과제

목적



- 학습 속도 개선: SGD, Adam 등 다양한 Optimizer 비교
- 초기값의 중요성: Xavier vs He Initialization 성능 평가
- 일반화 성능 확보: 배치 정규화 및 오버피팅 방지 기법 적용

"동일한 신경망 구조에서 최적화 전략이 모델의 수렴 속도와 최종 정확도에 미치는 영향을 정량적으로 분석합니다."

프로젝트 구조

Neural_Network_Project

├── common

│ ├── __init__.py
│ ├── functions.py
│ ├── layers.py
│ ├── optimizer.py
│ ├── util.py
│ ├── multi_layer_net.py
│ ├── multi_layer_net_extend.py
│ └── gradient.py

├── data

│ └── fashion
│ ├── t10k-images-idx3-ubyte.gz
│ ├── t10k-labels-idx1-ubyte.gz
│ ├── train-images-idx3-ubyte.gz
│ └── train-labels-idx1-ubyte.gz

├── utils

│ ├── __init__.py
│ ├── argparse.py
│ ├── helper.py
│ └── mnist_reader.py

├── network_Team7.pkl

├── activation_init_compare_fashion_mnist.py
├── depth_compare_fashion_mnist.py
├── dropout_compare_fashion_mnist.py
├── weight_decay_compare_fashion_mnist.py
├── optimizer_compare_fashion_mnist.py
├── train_fashion_mnist_team7_final.py
├── train_fashion_mnist_team7.py
└── README.md

- common/: 신경망 계층, 최적화 함수 등 공통 모듈
- data/: Fashion MNIST 데이터
- utils/: MNIST reader
- dropout_compare_fashion : 드롭아웃 구현
- train_fashion_mnist_team7 : pkl로 만들어짐

방법론 & 설계

Multi-Layer Perceptron (MLP)

계층 (Layer)	설정 (Configuration)
Input Layer	784 Nodes (28 x 28 Image Flatten)
Hidden Layers	4~5 Layers, 각각 100 Nodes
Activation	ReLU (Rectified Linear Unit)
Output Layer	10 Nodes (Softmax Classification)

CONCLUSIONES



OPTIMIZERS

SGD: 기본 확률적 경사 하강법
Momentum: 관성 적용
AdaGrad: 학습률 적응형 조정
Adam: 모멘텀 + 적응형 학습률



WEIGHT INITIALIZATI ON

Std=0.01: 표준편차 0.01 (가우시안)
Xavier: Sigmoid/Tanh에 최적
He: ReLU에 최적화된 초기값



REGULARIZA TION

Batch Normalization: 학습 안정화
Dropout: 뉴런 무작위 비활성
Weight Decay: L2 규제 적용

학습 과정

Hyperparameters

- ataset: Fashion MNIST (60,000 Train / 10,000 Test)
- Batch Size: 128
- Iterations: 2,000 (약 20 Epochs)
- Learning Rate: 0.01 (Optimizer별 미세 조정)

학습 과정

1

DATA LOAD

Fashion MNIST 데이터 로드 및 정규화 (0~1.0)

2

FORWARD

Affine -> ReLU -> ... -> Softmax 계층 통과 및 Loss 계산

3

BACKWARD

오차역전파법 (Backprop)을 통한 각 계층의 기울기 (Gradient) 산출

4


UPDATE

Optimizer 규칙에 따라 가중치(Weights) 갱신


분석 결과

Optimizer

Test Accuracy by Optimizer




Optimizer Comparison on Fashion-MNIST (Smoothed Train Loss)





분석 결과

weight-decay



분석 결과


depth




분석 결과

activation_init

Test Accuracy vs Activation & Initialization




Effect of Activation & Initialization (Train Loss)



분석 결과

dropout_compare_accuracy



분석 결과

He의 우수성

- Std=0.01: 활성화 값이 0에 치우쳐 기울기 소실(Vanishing Gradient) 발생. 학습 실패.
- Xavier: Sigmoid에 적합하나, ReLU에서는 층이 깊어질수록 값이 치우침.
- He Init: ReLU에 최적화된 초기값. 넓은 분포를 유지하여 깊은 신경망에서도 학습이 원활함.

Batch Normalization

- 학습 속도 가속: 훨씬 적은 Epoch으로 높은 정확도 도달.
- 초기값 의존도 감소: 가중치 초기값에 덜 민감하게 반응하여 안정적 학습 가능.
- 규제 효과: Dropout 없이도 오버피팅 억제 효과 일부 존재.

결론 및 향후 과제

최종 요약

- Optimizer: Adam이 Fashion MNIST 데이터셋에서 가장 빠르고 안정적인 수렴을 보여줌.
- Weight Init: ReLU 활성화 함수 사용 시 He Initialization이 필수적임.
- Batch Norm: 학습 시간을 획기적으로 단축시키며, 초기값 설정 실패 확률을 낮춤.
- 종합: Adam + He Init + Batch Normalization 조합이 최적의 성능을 발휘함.

결론 및 향후 과제



Data Augmentation


회전, 이동, 반전 등을 통한 데이터
증강으로 모델의 일반화 성능 추가
확보



Hyperparameter Tuning

Random Search 또는 Bayesian
Optimization을 활용한 체계적인
하이퍼파라미터 최적화

협업 과정



소감

강우현 : 팀원과의 소통 문제가 있었지만 잘 해결해나가며 협업하는 과정이 인상 깊었습니다.

한동운 : 배울 내용이 많아서 처음에는 어려웠지만, 직접 실험하고 눈으로 성능 차이를 팀원들과 확인해보며, 신경망에 대한 이해도가 확실히 높아졌습니다.

황지인 : 팀플을 통해 수업 때 배운 내용을 활용할 수 있어서 신경망 공부에 도움이 되었습니다.

**THANK'S
FOR
WATCHING**

